Прогноз направления доходности акций методами машинного обучения

Практическое задание «ML-моделирование в финансах», вариант 3 · Oct 21, 2026 · @Арина

1. Постановка задачи

Цель работы — проверить, можно ли с помощью машинного обучения прогнозировать направление доходности акций на 5 торговых дней вперёд и принимать на этой основе более выгодные инвестиционные решения, чем стратегия «купи и держи».

Целевая переменная — знак доходности акции за следующие 5 торговых дней: 1, если цена закрытия через 5 дней выше текущей, и 0 — иначе. Дата наблюдения — торговый день.

Ключевые метрики:

- статистические — ROC-AUC и коэффициент Gini (Gini = 2 × ROC-AUC − 1);
- финансовые — доходность, коэффициент Sharpe и максимальная просадка стратегии на бэктесте с комиссией 0,1% за сделку в сравнении с «купи и держи»;
- стабильность — индекс PSI между обучающим и тестовым периодами.

Сравниваются две модели: интерпретируемая логистическая регрессия (базовая) и градиентный бустинг LightGBM.

2. Данные и признаки

Использованы дневные скорректированные цены закрытия и объёмы торгов 10 американских акций из разных отраслей за 2 января 2015 — 14 октября 2026 года (источник — Yahoo Finance через библиотеку yfinance, auto_adjust=True). По каждой акции — 2 963 торговых дня, всего 29 630 наблюдений; пропусков и дубликатов пар «дата — тикер» нет.

Тикер	Компания	Отрасль
AAPL	Apple	Технологии
MSFT	Microsoft	Программное обеспечение

Тикер	Компания	Отрасль
AMZN	Amazon	Электронная торговля, облачные сервисы
GOOGL	Alphabet	Интернет-сервисы
NVDA	NVIDIA	Полупроводники
JPM	JPMorgan Chase	Банки
KO	Coca-Cola	Потребительские товары
WMT	Walmart	Розничная торговля
XOM	Exxon Mobil	Энергетика
JNJ	Johnson & Johnson	Здравоохранение

Из цен и объёмов построено 21 признак (10 на этапе 1 и 11 на этапе 2). Все признаки — числовые (float64), рассчитываются отдельно по каждой акции и сдвинуты на 1 день (shift(1)), т. е. используют только данные, известные до дня прогноза. Пропуски возникают только в начале ряда каждой акции (недостаточно истории для скользящего окна до 252 дней); такие строки удалены, поэтому обучающая выборка начинается с 2016 года.

Признак	Этап	Экономический смысл
ret_1	1	Доходность за 1 день — краткосрочное движение цены
ret_5	1	Доходность за 5 дней — недельный импульс
ret_20	1	Доходность за 20 дней — месячная динамика
momentum_60	1	Доходность за 60 дней — среднесрочный тренд
volatility_5	1	Ст. отклонение доходности за 5 дней — краткосрочный риск
volatility_20	1	Ст. отклонение доходности за 20 дней — месячный риск
ma_ratio_20	1	Отклонение цены от средней за 20 дней — перекупленность или перепроданность
ma_ratio_60	1	Отклонение от средней за 60 дней — положение относительно тренда

Признак	Этап	Экономический смысл
volume_change	1	Изменение объёма за день — всплеск активности
relative_volume_20	1	Объём относительно среднего за 20 дней — аномальная активность
rsi_14	2	Индекс относительной силы: больше 70 — перекупленность, меньше 30 — перепроданность
macd	2	EMA(12) / EMA(26) − 1 — сила и смена тренда
zscore_20	2	Отклонение цены от средней в ст. отклонениях (полосы Боллинджера)
vol_ratio	2	Волатильность 5 дн. / 20 дн. — рост риска в последние дни
drawdown_252	2	Падение от максимума за год
mom_12_1	2	Классический моментум: доходность за год без последнего месяца
volume_trend	2	Средний объём 5 дн. / 60 дн. — приток или отток интереса инвесторов
mkt_ret_5	2	Доходность «рынка» (среднее 10 акций) за 5 дней — общий фон
mkt_vol_20	2	Волатильность рынка за 20 дней — режим риска
rel_ret_20	2	Доходность акции минус доходность рынка за 20 дней — относительная сила
rank_ret_20	2	Место акции среди 10 по доходности за 20 дней (0–1)

3. Разбиение по времени и контроль утечки

Данные разделены по уникальным торговым датам, а не случайно: модель обучается на прошлом и проверяется на будущем. Все 10 акций за один день попадают в одну выборку.

Выборка	Доля дат	Период	Доля роста (target = 1)	Назначение
Train	70%	2016 — март 2023	56%	обучение моделей
Validation	15%	март 2023 — декабрь 2024	57%	подбор параметров, ранняя остановка, выбор порога
Test (out-of-time)	15%	30.12.2024 — 07.10.2026	57%	однократная финальная оценка

Меры против утечки данных:

1. Целевая переменная строится только через shift(−5) внутри каждой акции; последние 5 дней каждой акции, где будущая цена неизвестна, удалены.
2. Все признаки сдвинуты на 1 день (shift(1)) и считаются по скользящим окнам из прошлого (rolling).
3. Удалён из признаков столбец future_return_5d — будущая 5-дневная доходность, из которой строится целевая переменная (прямая утечка). Цена и объём текущего дня (Close, Volume) в модель не подаются.
4. Между выборками оставлен зазор 5 торговых дней: целевая переменная последних дней train рассчитана по ценам, которые уже относятся к validation, и без зазора информация из будущего попала бы в обучение.
5. Корреляция каждого признака с будущей доходностью близка к нулю — ни один признак не «знает» ответ.
6. Test не использовался до этапа 4 и был оценён один раз; после этого модель не изменялась.

4. Модели и их сравнение на validation

LightGBM превзошёл логистическую регрессию на validation (Gini 0,071 против 0,013), но оба сигнала слабые.

Базовая модель. Логистическая регрессия в конвейере SimpleImputer (медиана) → StandardScaler → LogisticRegression (class_weight="balanced", random_state=42). Сила регуляризации C подобрана на validation из {0,0001; 0,001; 0,01; 0,1; 1}; лучшее значение C = 0,0001. Добавление 11 признаков этапа 2 улучшило Gini с −0,039 до −0,013 (при C = 1). На train ROC-AUC равен 0,542, на

validation — 0,494: закономерности прошлого не сохранились в период роста 2023–2024 годов, особенно для защитных бумаг (ROC-AUC: JNJ 0,443; XOM 0,451; JPM 0,450).

Градиентный бустинг. LightGBM с ранней остановкой (100 итераций без улучшения ROC-AUC на validation). Параметры подобраны перебором 18 комбинаций на validation, без KFold: num_leaves ∈ {7, 15, 31}, min_child_samples ∈ {200, 500, 1000}, reg_lambda ∈ {0, 5}; learning_rate = 0,01, subsample = 0,8, colsample_bytree = 0,8. Лучшая модель — самая простая: num_leaves = 7, min_child_samples = 1000, reg_lambda = 0, 65 деревьев; все шесть лучших конфигураций имели num_leaves = 7. Параметры записаны в config.yaml. Так как классы почти сбалансированы, калибровка вероятностей для варианта 3 не требуется.

Модель (validation)	ROC-AUC train	ROC-AUC validation	Gini validation
Логистическая регрессия (C = 0,0001)	—	0,506	0,013
LightGBM	0,588	0,536	0,071

В линейной модели весомее всего относительная сила акции и моментум (положительное влияние), а также MACD и отклонение от 60-дневной средней (отрицательное — возврат к среднему). У LightGBM с большим отрывом важнее всего волатильность рынка mkt_vol_20: бустинг улавливает нелинейную связь с рыночным режимом, недоступную линейной модели. Оценка на validation оптимистична: эта выборка использовалась и для ранней остановки, и для выбора параметров. Для финальной проверки выбран LightGBM.

5. Оценка на test и финансовый эффект

На out-of-time test (январь 2025 — октябрь 2026) модель не показала прогнозной силы, а стратегия на её основе заработала +5,3% против +57,5% у «купи и держи».

Модель (test)	ROC-AUC	Gini
Логистическая регрессия	0,485	−0,030
LightGBM	0,502	0,003

Правила стратегии. Раз в 5 торговых дней (горизонт прогноза) для каждой акции открывается позиция на 1/10 капитала, если прогнозная вероятность роста p больше порога; иначе эта доля остаётся в деньгах. Комиссия — 0,1% от оборота. Бенчмарк — равновзвешенный портфель из тех же 10 акций («купи и держи»). Sharpe рассчитан по дневным доходностям с аннуализацией √252, без безрисковой ставки.

Выбор порога. Кандидаты — квантили прогнозов на validation (от 20-го до 80-го); выбран порог p > 0,5815 с максимальным Sharpe на validation. На test порог не подбирался.

Портфель	Выборка	Доходность за период	Годовая доходность	Sharpe	Макс. просадка	Время в позиции
Стратегия (LightGBM)	test	+5,3%	+3,0%	0,37	−8,4%	26%
Купи и держи	test	+57,5%	+30,1%	1,84	−18,0%	100%
Стратегия (LightGBM)	validation	+42,5%	+23,1%	2,82	−4,9%	30%
Купи и держи	validation	+72,8%	+37,8%	2,68	−8,2%	100%

На validation стратегия уступала рынку по доходности, но имела чуть более высокий Sharpe и меньшую просадку. На test это преимущество исчезло: из всех метрик лучше только просадка, и та объясняется тем, что три четверти времени капитал находился в деньгах. В апреле 2025 года стратегия избежала части падения, но пропустила последующий рост рынка. Разрыв между validation и test подтверждает, что многократное использование validation (ранняя остановка, параметры, порог) даёт завышенную оценку.

Рисунок: кривые капитала на test — файл fig_backtest.png из ноутбука 04_evaluation.

6. Интерпретация модели (SHAP)

Модель в основном реагирует на волатильность рынка и на эффекты возврата к среднему; выбрать лучшую акцию среди десяти она почти не умеет. SHAP-значения рассчитаны TreeExplainer на test в шкале лог-шансов; средний прогноз E[f(x)] = 0,273, что соответствует вероятности роста примерно 0,57.

Общая картина (summary plot, файл fig_shap_summary.png):

- **mkt_vol_20** — главный признак. Экстремально высокая волатильность рынка сильно снижает вероятность роста (до −0,12): в панику модель «не покупает». Умеренно повышенная и низкая — повышают.

- **volatility_5, vol_ratio** — после всплеска краткосрочной волатильности акции модель ждёт отскока.
- **rel_ret_20** — акции, обгонявшие рынок за месяц, получают небольшой плюс (относительная сила).
- **relative_volume_20** — аномально высокий объём снижает вероятность роста: часто это реакция на плохие новости.
- **drawdown_252, momentum_60** — глубокая просадка и слабый моментум повышают вероятность: логика «покупай на падении».

Разбор трёх наблюдений из test (waterfall-графики fig_shap_case1–3.png):

Наблюдение	p	Факт	Главные вклады SHAP
1. JPM, 24.02.2025 — самая уверенная покупка	0,606	падение (ошибка)	mkt_vol_20 = 0,82% (+0,068); vol_ratio = 1,57 (+0,058); volatility_5 = 2,15% (+0,033)
2. KO, 15.05.2025 — самый уверенный отказ	0,531	падение (верно)	mkt_vol_20 = 1,26% (−0,092); rel_ret_20 = −11,7% (−0,017); vol_ratio = 0,76 (−0,009)
3. XOM, 12.08.2026 — уверенная верная покупка	0,606	рост (верно)	mkt_vol_20 = 0,85% (+0,066); vol_ratio = 1,58 (+0,052); volatility_5 = 2,48% (+0,027)

Наблюдение 1. На спокойном рынке у JPM резко выросла краткосрочная волатильность, и модель ждала отскока. На деле это было начало распродажи февраля–апреля 2025 года; смену режима по прошлым ценам предвидеть нельзя.

Наблюдение 2. После апрельского обвала волатильность рынка оставалась повышенной, а Coca-Cola за месяц отстала от рынка на 11,7%: рынок рос за счёт технологических компаний. Оба фактора снизили прогноз, и он оказался верным. При этом даже самый уверенный отказ имеет p = 0,531 > 0,5.

Наблюдение 3. Ситуация почти точно повторяет первую: спокойный рынок и всплеск волатильности акции дали ту же вероятность 0,606, но на этот раз цена выросла.

Наблюдения 1 и 3 показывают суть проблемы: одинаковые драйверы приводят к противоположным исходам. Все прогнозы на test лежат в узком диапазоне 0,53–0,61, то есть модель почти не различает ситуации.

7. Стабильность (PSI)

Главный признак модели mkt_vol_20 нестабилен (PSI = 0,87), и это главная причина деградации модели на test. PSI рассчитан между train и test по 10 квантильным корзинам train для скора модели и пяти самых важных признаков (по gain).

Переменная	PSI	Вывод
mkt_vol_20	0,873	нестабилен (> 0,25)
Скор модели (p)	0,165	умеренный сдвиг
volatility_5	0,107	умеренный сдвиг
rel_ret_20	0,037	стабилен
relative_volume_20	0,008	стабилен
vol_ratio	0,005	стабилен

Причина нестабильности mkt_vol_20. В train вошли периоды очень высокой волатильности — паника марта 2020 года и спад 2022 года, а test в основном пришёлся на спокойный растущий рынок с одним коротким всплеском в апреле 2025 года. Распределение признака сместилось, и правила, выученные моделью для разных уровней волатильности, в новом периоде перестали работать. Относительные признаки (vol_ratio, rel_ret_20, relative_volume_20) стабильны, потому что сами нормированы на текущий режим.

8. Ограничения и выводы

Ограничения:

- Всего 10 крупных ликвидных акций США; «рынок» в рыночных признаках — среднее по этим акциям, а не широкий индекс.
- Список акций выбран сегодня, среди компаний, которые стали крупнейшими, — это смещение выживших, которое завышает доходность «купи и держи».
- Используются только цены закрытия и объёмы; фундаментальные данные, новости и макропоказатели (ставки, VIX) не учитываются.
- Validation использовалась для ранней остановки, подбора параметров и порога, поэтому оценки на ней оптимистичны.
- Модель обучена один раз и не переобучается по мере поступления новых данных (walk-forward), что делает её уязвимой к смене режима.

- Бэктест упрощён: сделки по цене закрытия без проскальзывания, деньги вне позиции не приносят процент, Sharpe — без безрисковой ставки, налоги не учтены.
- Дивиденды учтены только через скорректированные цены (auto_adjust).

Выводы:

1. На validation градиентный бустинг превзошёл логистическую регрессию (Gini 0,071 против 0,013) за счёт нелинейной реакции на рыночную волатильность.
2. На out-of-time test прогнозная сила не подтвердилась: ROC-AUC = 0,502, Gini = 0,003.
3. Стратегия на основе модели принесла +5,3% (Sharpe 0,37) против +57,5% (Sharpe 1,84) у «купи и держи»; меньшая просадка (−8,4% против −18,0%) объясняется пребыванием в деньгах, а не качеством прогноза.
4. Причина — смена рыночного режима: главный признак mkt_vol_20 имеет PSI = 0,87, а одинаковые сигналы модели приводят к противоположным исходам (наблюдения 1 и 3).
5. На рассмотренных данных модель не имеет практической ценности для инвестиционных решений. Это согласуется с гипотезой эффективного рынка: для крупных ликвидных акций прошлые цены и объёмы почти не содержат устойчивой информации о недельном направлении цены.

Возможные улучшения: расширить выборку до 30–50 акций, добавить внешние рыночные индикаторы (VIX, S&P 500, доходность 10-летних облигаций США), использовать walk-forward-переобучение и нормировать рыночные признаки на их недавнюю историю, чтобы снизить PSI.